Търсене и извличане на информация. Приложение на дълбоко машинно обучение

Зимен семестър 2024/2025

Домашно задание №3

2 януари 2025 г.

Общ преглед

В това задание ще имплементираме Дълбок невронен поет, който автоматично ще генерира поеми на български[1]. За целта ще обучим поета използвайки 14000 поеми на български. Поета ще реализираме чрез използване на рекурентна невронна архитектура. По-конкретно, архитектурата е многослойна еднопосочна LSTM рекурентна невронна мрежа представена на фигура 1. За да се генерират поеми със стила на конкретен български поет, ние с невронната мрежа ще моделираме условен езиков модел, като за условие ще се използва влагане на името на автора. Влагането на автора ще се подава за начален скрит вектор на LSTM мрежата. Входът е влагането на автора и последователност от влагания на символите на поемата, а след последното LSTM ниво, скритият вектор след dropout се проектира през линейна трансформация върху символите. Накрая, след softmax се получава разпределение за следващия символ в последователността.

Обучението ще извършим като минимизираме крос-ентропията на така съставения условен езиков модел на ниво символи.

[1]Генераторът на поеми, предмет на това задание, е сравнително примитивен. Генерираните от него поеми не се римуват добре и нямат особен смисъл. В тази област има по-задълбочени подходи, които могат да генерират поеми със значително по-високо качество. Вижте например: Deep-speare: A joint neural model of poetic language, meter and rhyme, Lau et al, 2018 http://aclweb.org/anthology/P18-1181

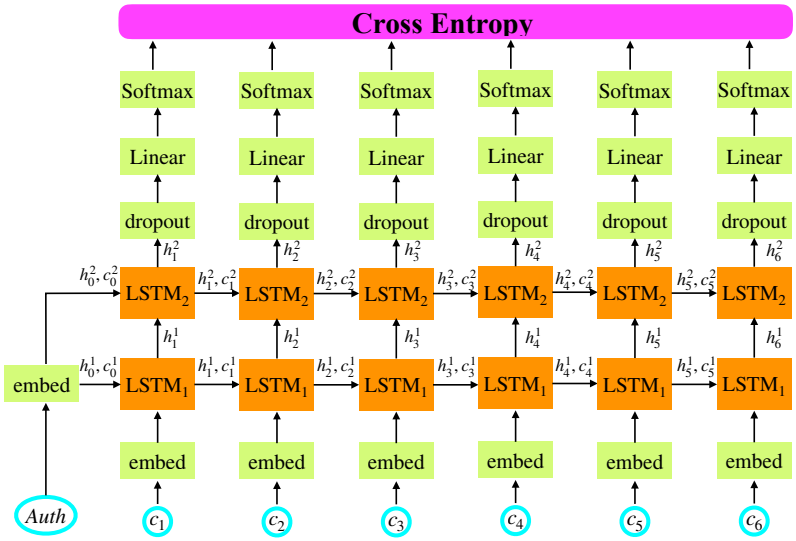

Фигура 1: Архитектура на рекурентната невронна мрежа, реализираща Дълбок невронен поет. Рекурентната невронна мрежа моделира условен вероятностен модел. При подаден автор и последоветелност от символи моделът връща вероятностно разпределение за следващия символ в последователността. Името на автора се влага в началните скрити вектори $h_0^1, c_0^1, h_0^2, c_0^2$. Вероятностното разпределение за $n+1$-вата дума се получава от softmax върху проекцията на n-тия скрит вектор – h_n^2.

Генерирането на нови поеми се извършва по следната процедура: Началният скрит вектор h_0 и памет c_0 се получават от влагане на автора. Започва се с произволен начален низ от символи, който следва да започва със символа за начало на последователност '{' (може да се състои и само от този символ). С този начален низ се траверсира рекурентната невронна мрежа до получаването на съответната двойка от скрит вектор h и памет c. От h се получава разпределението Pr за следващия символ. Следващия символ се генерира случайно с разпределение Pr. Този символ се добавя към резултата и с него се захранва рекурентната невронна мрежа за получаване на следващата двойка от скрит вектор h и памет c. Тази процедура се повтаря до генерирането на символ за край на последователност или до достигане на даден лимит. На фигура 2 е представена схема на генератора на поеми.[2]

Забележки

1. За това задание не се предоставя код за тестване. Препоръчва се вие сами да си направите тестови скриптове, с които да се уверите в коректността на програмите ви. Също така, в кода подсказките са силно ограничени и вие имате по-голяма свобода за структурирането на вашата програма.

2. Въпреки, че са дадени примерни стойности за метапараметрите като брой слоеве, размери на влагания, размер на скритите вектори, dropout, размер на партидата и т.н., вие имате пълната свобода да ги променяте, за да получите по-добри резултати. Това, което ще бъде оценено накрая, е доколко добре се справя вашата програма с поставената задача.

3. За обучението на модела може да ви бъде необходимо значително повече машинно време. Ако не разполагате с мощен компютър с графичен ускорител може да се възползвате от услугата Google Colab, където безплатно се предоставя изчислителна среда с инсталирани Python и Pytorch, която може да се конфигурира да използва графична карта (GPU). Очаква се времето за обучение при използването на графична карта да е около 1-2 часа.

[2]Подобен генератор и други приложения на генератора може да намерите на страница: http://karpathy.github.io/2015/05/21/rnn-effectiveness/.

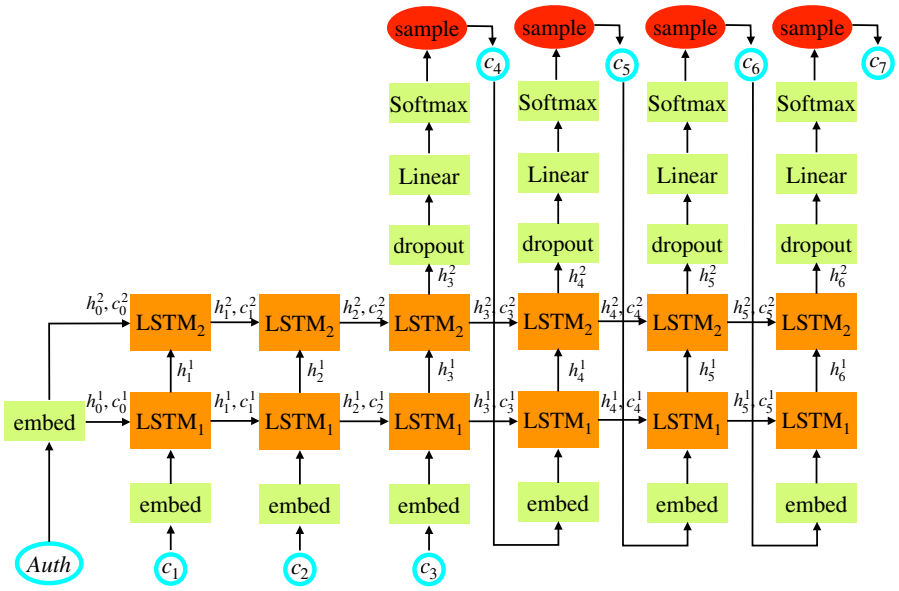

Фигура 2: Схема на невронната мрежа за генериране на поеми. В конкретния случай е представена двуслойна LSTM рекурентна невронна мрежа. На входа е зададен начален низ $c_1c_2c_3$. От скрития вектор h_3^2, след dropout, проектиране и softmax се получава разпределение, с което се семплира следващия символ c_4. Този символ се извежда и се подава като следващ символ на рекурентната невронна мрежа. Тази процедура се повтаря до извеждането на символ за край или достигането на зададен лимит.

Задача 1 (5 точки)

Задачата е да имплементирате езиковия модел на дълбокия невронен поет като допълните кода във файла `model.py`. За целта може да копирате части от кода от упражнения 12 и 13, в които се имплементира еднопосочен LSTM с пакетиране на партиди. Към вашия код е необходимо да добавите следните допълнения:

1. Влагане на автора в начални скрити вектори h_0, c_0 на LSTM.
2. Възможност за задаване на повече нива на LSTM.
3. Допълнителен dropout слой след последния LSTM слой, преди линейната проекция.

След като реализирате езиковия модел следва да го обучите. В пакета със заданието е включен файла `corpusPoems`, който съдържа 14000 поеми на български език, извлечени от сайта http://chitanka.info. Във файла `utils.py` са имплементирани функциите за подготовка на тренировачни данни. Вие първо трябва да подготвите данните като извикате:

```
python run.py prepare
```

След това тренирането става с извикването на програмата:

```
python run.py train
```

След завършване на обучението, програмата оценява перплексията на ниво символи на езиковия модел. Получената перплексия следва да е значително по-малка от 5, по възможност около 4.15. Желателно е да опитате да получите възможно най-добра стойност на перплексията, като променяте стойностите на метапараметрите във файла `parameters.py`. Оценката ви ще зависи от получената перплексия.

Забележка: След успешна процедура по трениране, параметрите на модела се записват във файла `modelFileName = 'modelLSTM'`. Може да донатренирате вече запазен модел като извикате:

```
python run.py train modelLSTM
```

Перплексията на вече записан модел може отново да измерите с командата:

```
python run.py perplexity
```

Задача 2 (5 точки)

В тази задача трябва да реализирате процедура за генериране на поема. За целта трябва да попълните функцията `generateText` във файла

`generator.py`, като имплементирате процедурата, която е скицирана на фигура 2. Забележки:

1. По време на генерация за получаването на разпределението върху следващия символ ще добавим параметър "температура". Поконкретно вместо стандартното разпределението $p = \text{softmax}(\mathbf{z})$, където $\mathbf{z}$ е проекцията на последния скрит вектор върху символите, ще използваме разпределението $p_\tau = \text{softmax}(\mathbf{z}/\tau)$, където τ е параметър наречен температура. Варирането на този параметър в интервала $[0, 1]$ води до промяна на увереността на поета. По-високите стойности водят до по-разхвърляни (съдържащи повече правописни грешки) поеми. По-ниските стойности водят до по-регулярни текстове.

2. За семплирането на елемент с дадено разпределение може да използвате вградената в NumPy функция `numpy.random.choice`.

След като реализирате генератора може да го използвате за генериране на поеми с командата:

```
python run.py generate ''Иван Вазов''
```

Към командата може да зададете начален низ и температура:

```
python run.py generate ``Димчо Дебелянов'' ``{Да се завърнеш''
python run.py generate ``Димчо Дебелянов'' ``{Да се завърнеш'' 0.4
```

Инструкция за предаване на домашна работа

Изисква се в Moodle да бъде предаден архив FNXXX.zip (където XXX е вашият факултетен номер), който съдържа:

1. Файловете `model.py, parameters.py, generator.py` съдържащи нанесените от вас промени

2. Файлът `modelLSTM` получен след изпълнението на Задача 1

3. Текстът на някоя по-успешната поема (по ваш избор) на вашия поет при празен начален низ.

Надявам се, че ще се забавлявате.